Jak pisać w C i nie zwariować

Krzysztof Kuźnik

Mateusz Kwiatkowski



Dlaczego pisać w C, skoro jest...

- Python, Ruby, JavaScript, ...
 - performance
 - bolączki dynamicznego typowania, zwłaszcza w większych projektach
- Java, Scala, C#, ... (JVM/.NET)
 - performance?
 - mit (zwykle)
 - wsparcie dla akceleracji sprzętowej
 - niedeterministyczne zarządzanie pamięcią
 - systemy czasu rzeczywistego
 - platforma jest DUŻA
 - ▶ JRE ~150 MB

Dlaczego pisać w C, skoro jest...

- C++, Rust, ...
 - ▶ Jak skompilować kompilator Rusta na egzotyczną architekturę?
 - ► ROZMIAR
 - ► libstdc++ 1,5 MB
 - ► Rozwinięcia szablonów...?
 - ► Rust libstd 4 MB
 - eglibc 1,8 MB a powyższe i tak jej wymagają!
 - ▶ uClibc **560 KB**
 - ▶ dietlibc 185 KB

C "studenckie"

- Programy w jednym pliku
- ► BFG (big fucking globals)
- C++ (C with classes)
- Zalegizować STL? A komu to potrzebne?
- Printf debugging
- A może jednak Java?
- Przecież C i C++ to jest to samo
- C jest dla linuxowych freaków bo już nawet naukowcy używają Pythona

C "profesjonalne"

- Narzędzia
- Budowanie projektu
- Zarządzanie pamięcią
- Unikanie pułapek
- Wzorce projektowe

Narzędzia prawdziwego programisty

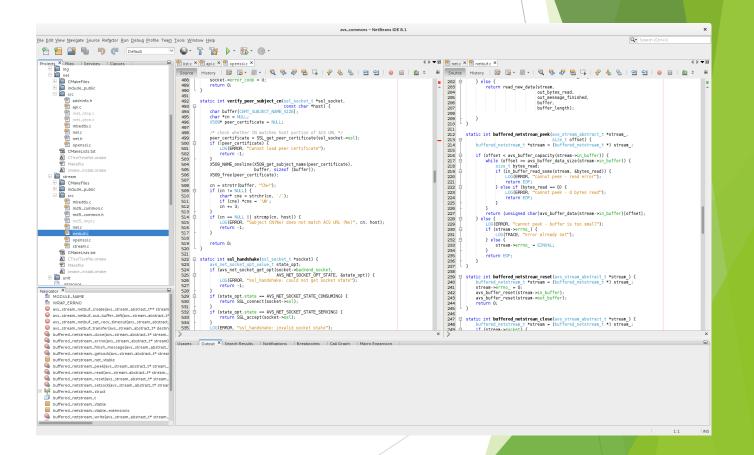
Narzędzia prawdziwego programisty: Miejsce tworzenia

- W projektach studenckich (2-3 jednostki translacji) można pisać w gedit/Notepad++ i kompilować z konsoli...
- W prawdziwym życiu prawdziwych ludzi przyda się IDE
 - vim / Emacs / ... + masa pluginów
 - Visual Studio skomplikowana licencja, tylko Windows
 - ► Eclipse + CDT
 - NetBeans



NetBeans jako IDE do C/C++

- Obsługuje standardowe formaty projektów (Make, CMake, ...)
- Nawigacja po kodzie
 - ► Ctrl+klik, Alt+F7
- GUI do debuggera
- Pro tipy:
 - Przebuduj kod z poziomu IDE, żeby odświeżyć strukturę projektu
 - Łatwy podgląd nagłówków bibliotecznych, rozwijanie makr
- Jakieś wady?
 - Żabkuje:(



Narzędzia prawdziwego programisty: Plac budowy

- Wywoływanie kompilatora z terminala szybko staje się problematyczne...
- Zarządzanie projektem przez IDE?
 - Utrudniamy życie ludziom, którzy będą chcieli po prostu ściągnąć i zbudować projekt
 - Np. wykładowcom (つもつ)
- Surowe Makefile
 - Ograniczone możliwości
 - Nie wykrywa zmian w nagłówkach
 - Problem z wyszukiwaniem bibliotek
- GNU autotools
- CMake

CMake

- https://cmake.org/
- Tutorial: https://cmake.org/cmake-tutorial/
- Nakładka na make
 - cmake . generuje Makefile (lub projekt VS, ...) make - właściwe budowanie
- Opis projektu szybko się rozrasta
 - ▶ CMake jest w pełni funkcjonalnym językiem skryptowym... ರ_ರ
 - Mimo wszystko, stosunkowo dobrze się skaluje
- Natywnie wspierany przez CLiona
- Stosunkowo dobrze działa z Eclipse i NetBeans
 - Najlepiej najpierw stworzyć szkielet projektu CMake i później importować!

Narzędzia prawdziwego programisty: Gabinet postępowania kryzysowego

- Analiza statyczna
- Analiza dynamiczna
- Debugger



Analiza statyczna

- Clang Static Analyzer: scan-build
- cmake
 -DCMAKE_C_COMPILER=
 {...}/ccc-analyzer .

scan-build make

Wykrywa wiele typowych błędów logicznych przed uruchomieniem programu

```
n2s(p, payload);
              pl = p;
1466
1467
              if (s->msg_callback)
              1 Taking false branch →
1468
                       s->msg_callback(0, s->version, TLS1_RT_HEARTBEAT,
1469
                                &s->s3->rrec.data[0], s->s3->rrec.length,
1470
                                s, s->msg callback arg);
1471
1472
              if (hbtype == TLS1 HB REQUEST)
                  2 ← Assuming 'hbtype' is equal to 1 →
                 ← Taking true branch →
1473
1474
                       unsigned char *buffer, *bp;
1475
                       int r;
1476
1477
                       /* Allocate memory for the response, size is 1 byte
1478
                        * message type, plus 2 bytes payload length, plus
1479
                        * payload, plus padding
1480
1481
                       buffer = OPENSSL_malloc(1 + 2 + payload + padding);
1482
                       bp = buffer;
1483
1484
                       /* Enter response type, length and copy payload */
1485
                       *bp++ = TLS1 HB RESPONSE;
1486
                       s2n(payload, bp);
1487
                       memcpy(bp, pl, payload);
                     4 ← Tainted, unconstrained value used in memcpy size
```

Analiza dynamiczna

- Valgrind
- ► Różne narzędzia, podstawowe: Memcheck
- valgrind ./prog
- valgrind --leak-check=full ./prog
- Inne narzędzia:
 - ▶ valgrind --tool=...
 - Helgrind wykrywa błędy w programach wielowątkowych
 - Massif profilowanie zużycia pamięci
 - Callgrind profilowanie kodu
 - **...**
- Alternatywy:
 - clang -fsanitize=...

```
File Edit View Jerminal Tabs Help
[pwells2@newcell ~/junk]$ valgrind ./memleak
==16738== Memcheck, a memory error detector
==16738== Copyright (C) 2002-2010, and GNU GPL'd, by Julian Seward et al.
==16738== Using Valgrind-3.6.1 and LibVEX; rerun with -h for copyright info
==16738== Command: ./memleak
--16738--
==16738== Invalid write of size 4
==16738==
           at 0x400589: main (mem leak.c:32)
==16738== Address 0x4c26068 is 0 bytes after a block of size 40 alloc'd
            at 0x4A0646F: malloc (vg replace malloc.c:236)
            by 0x400505: main (mem leak.c:17)
==16738==
--16738---
==16738== Invalid read of size 4
==16738==
             at 0x400598: main (mem_leak.c:33)
           Address 0x4c26068 is 0 bytes after a block of size 40 alloc'd
==16738==
            at 0x4A0646F: malloc (vg_replace_malloc.c:236)
             by 0x400505: main (mem_leak.c:17)
--16738--
--16738---
==16738== HEAP SUMMARY:
==16738==
              in use at exit: 410 bytes in 8 blocks
==16738==
           total heap usage: 11 allocs, 3 frees, 590 bytes allocated
==16738==
==16738== LEAK SUMMARY:
--16738--
             definitely lost: 410 bytes in 8 blocks
--16738--
             indirectly lost: \theta bytes in \theta blocks
               possibly lost: \theta bytes in \theta blocks
==16738==
==16738==
             still reachable: θ bytes in θ blocks
==16738==
                  suppressed: 0 bytes in 0 blocks
==16738== Rerun with --leak-check=full to see details of leaked memory
==16738== For counts of detected and suppressed errors, rerun with: -v
==16738== ERROR SUMMARY: 36 errors from 2 contexts (suppressed: 4 from 4)
[pwells2@newcell ~/junk]$
```

Debugger

- ► Gdb
- "Printf debugging" nie zawsze jest złe, ale debugger daje więcej możliwości
- Surowy gdb jest trochę toporny
 - UI w IDE
 - gdb-dashboard
 https://github.com/cyrus-and/gdbdashboard
- Dodatkowe narzędzia:
 - gdbserver zdalne debugowanie
 - ▶ valgrind --vgdb
 - rr

```
for (i = 0; i < n; i++) {
     oid fun(int n, char *data[])
      for (i = 0; i < n; i++) {
    printf("%d: %s\n", i, data[i]);</pre>
   int main(int argc, char *argv[])
   000100000f1a e8 4b 00 00 00 fun+58 callq
     00001000000f1f 89 45 e8
                                  fun+63 mov
                                 fun+74 mov
                                               %eax,-0x14(%rbp)
0x100000ef6 <fun+22>
     0000100000f2a 89 45 ec
                                 fun+77 jmpq
     0000100000f32 48 83 c4 20
                                 fun+82 add
                                               $0x20,%rsp
                                  fun+86 pop
Threads
[1] id 4355 from 0x0000000100000f2a in fun+74 at scrot.c:7
0] from 0x0000000100000f2a in fun+74 at scrot.c:7
 rq n = 3
 rg data = 0x7fff5fbffb60
  ci = 1
 1] from 0x00000001000000f62 in main+34 at scrot.c:14
 rg argc = 3
   argv = 0x7fff5fbffb60
                              rcx 0x0000010000000203
                                                           rdi 0x00007fff79e86118
                              rsp 0x00007fff5fbffb00
   rbp 0x00007fff5fbffb20
                                                           r8 0x000000000
                              r10 0xffffffffffffffff
   r9 0x00007fff79e86110
                                                           r14 0x00000000000000000
                              r13 0x00000000000000000
                                                        eflags [ TF IF ]
   cs 0x0000002b
                               ss <unavailable>
                                                            ds <unavailable>
   es <unavailable>
   Expressions
   9007fff5fbffblc 03 00 00 00 40 fb bf 5f ff 7f 00 00 62 0f 00 00 ....@.._...b...
    007fff5fbffb2c 01 00 00 00 60 fb bf 5f ff 7f 00 00 03 00 00 00 ....`.._.....
 <000007fff5fbffb3c 00 00 00 00 50 fb bf 5f ff 7f 00 00 ad 15 f7 9c ....P.._.....</p>
   0007fff5fbffcf0 68 65 6c 6c 6f 00 47 44 42 00 54 45 52 4d 5f 50 hello.GDB.TERM
   History
 $0 = {[0] = 0x7fff5fbffcf0 "hello", [1] = 0x7fff5fbffcf6 "GDB"}
```

Inne narzędzia

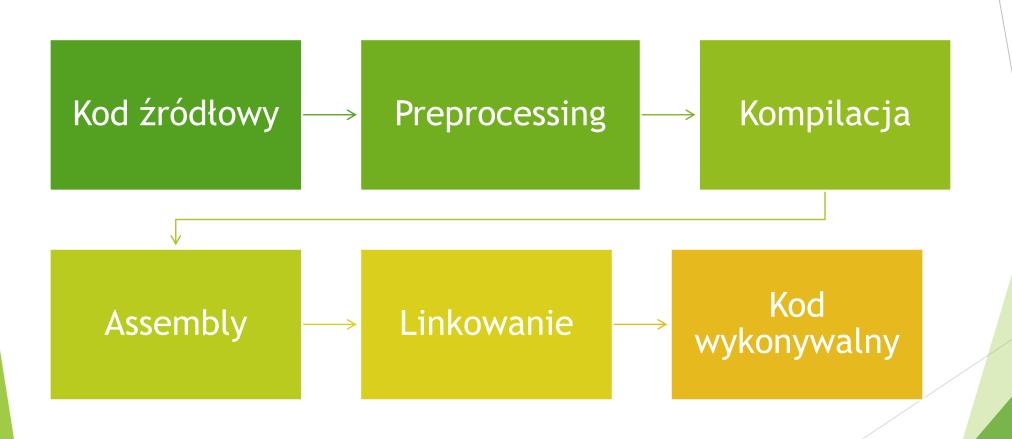
- Profiler
- Unit testing library
- Fuzzer
- Doxygen

Budowanie projektu

A może by tak podzielić program na wiele plików?



Etapy "kompilacji"



Jednostka translacji

- Plik źródłowy po preprocessingu
- Czasem zwana też jednostką kompilacji
- Podstawa dla działania kompilatora
- Co się dzieje w trakcie preprocessingu?

```
// something is missing here
int main(void) {
   printf("Header files\n");
   return 0;
}
```

```
#include <stdio.h>
int main(void) {
    printf("Header files\n");
    return 0;
}
```

```
int printf(const char *, ...);
int main(void) {
    printf("Header files\n");
    return 0;
}
```

- Deklaracja musi być
- Definicja to też deklaracja
- Definicja symbolu musi być zgodna z deklaracją
- Deklaracje w jednym miejscu
- gcc -E

Kod obiektowy

- Kompilacja + assembly
- Cross-compiling
- Kontrola typów
- Optymalizacje
- gcc -S -masm=intel
- Kod maszynowy gotowy do linkowania
- gcc -c

Linkowanie

- Lączenie plików obiektowych
- Lączenie symboli
- Dołączenie bibliotek
- Setup środowiska

Najprostszy scenariusz

module.h

```
#ifndef _PROJEKT_MODULE_H_
#define _PROJEKT_MODULE_H_

void did_leo_get_his_oscar(void);
#endif /* _PROJEKT_MODULE_H_ */
```

module.c

```
#include <stdio.h>
#include <module.h>
void did leo get his oscar(void) {
  printf("Yes\n");
```

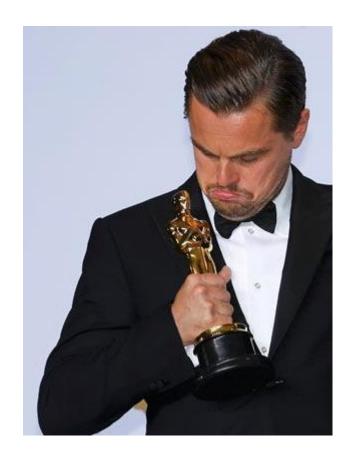
main.c

```
#include <module.h>
int main(void) {
    did leo get his oscar();
    return 0;
```

And the Oscar goes to...

```
$ gcc -Wall -pedantic -std=c99 -I. -o did_leo_get_his_oscar main.c module.c
```

\$./did_leo_get_his_oscar
Yes



Enkapsulacja!

- C nie ma namespace'ów ani przeładowania nazw funkcji
- static FTW!!!
- "prywatne" struktury

static (1/2)

```
int counter(void) {
    static int x = 0;
    return x++;
}
```

static (2/2)

```
static const char *IMPORTANT TEXT = "HTTP";
static const uint32 t DEFAULT VALUE = 8;
static uint32 t some internal function(void) {
    return DEFAULT VALUE;
extern uint32 t module public function (void);
uint32 t module public function (void) {
    return some internal function();
```

Przeźroczyste typy danych

Jak ograniczyć widoczność pól struktury?

main.c

```
#include <stdio.h>
#include <module.h>
int main(void) {
    student t *my student = NULL;
    if (!create student(&my student)) {
        printf("success");
        free student (my student);
    } else {
        printf("failure");
    return 0;
```

module.h

```
#ifndef PROJEKT MODULE H
#define PROJEKT MODULE H
struct student;
typedef struct student student t;
int create student(student t **);
void free student(student t *);
#endif /* PROJEKT MODULE H */
```

module.c

```
#include <module.h>
struct student {
  char name [257];
int create student(student t **student) {
    /* memory allocation & initialization */
void free student(student t *student) {
  free(student);
```

Zarządzanie pamięcią

Czy to jest aż tak trudne?

Cieknące zasoby

- Pamięć
- Deskryptory plików
 - Pliki
 - Sockety
 - Pipe'y
- Wątki



ZAWSZE sprzątaj swój bałagan

Złota zasada nr 1

```
int read data(void) {
    FILE *file1 = fopen("plik1", "r");
    FILE *file2 = fopen("plik2", "r");
    int result = -1;
    if (!file1 || !file2) {
     goto read_data_cleanup;
    } else {
     /* inne operacje na file1 i file2 */
      result = 0;
read data cleanup:
    if (file1) {
      fclose(file1);
    if (file2) {
      fclose(file2);
    return result;
```

"

Twoje funkcje powinny mieć tylko jedno słowo kluczowe return

Złota zasada nr 2

Nie jest to konieczne, ale jest bardzo pomocne w analizie kodu.

```
int read data(void) {
    FILE *file1 = fopen("plik1", "r");
    FILE *file2 = fopen("plik2", "r");
    int result = -1;
    if (!file1 || !file2) {
     goto read_data_cleanup;
    } else {
     /* inne operacje na file1 i file2 */
      result = 0;
read data cleanup:
    if (file1) {
      fclose(file1);
    if (file2) {
      fclose(file2);
    return result;
```

Zawsze minimalizuj zasięg dostępu do swoich danych

Złota zasada nr 3

Bloki kodu mają sens nie tylko przy instrukcjach sterujących. Jeżeli alokujesz jakiś zasób to staraj się go zwolnić w tej samej funkcji. (nie dotyczy to funkcji, które są nastawione na tworzenie lub usuwanie "instancji") "

True bugs wait...

http://natashenka.ca/posters/

I have a lot to look forward to in life. That's why using streat isn't an option. Only abstaining from streat can 100% protect me from overflows and memory disclosures





True Bugs Wait ♡

@natashenka #truebugswait

Just because I used gets before doesn't mean I have to use gets again. It's my choice! Now that I know more about gets, I'm waiting for a standard input function I can trust for life





True Bugs Wait O

@natashenka #truebugswait

Bezpieczeństwo

- strncat
- strlcpy
- snprintf
- strncmp
- ▶ NULL **terminator**
- Zawsze inicjalizuj zmienne (tablice, struktury, wskaźniki)

Przybywacie z krainy Pascala?

```
int main() {
  int i;
  int tab[10];
  for (i = 1; i <= 10; ++i) {
    tab[i] = 0;
  return 0;
```

Dawno, dawno temu, na serwerach Kl...

Co jest nie tak z tym kodem…?

Dawno, dawno temu, na serwerach Kl...

Rozwiązanie!

C99 jest fajne!

...i już prawie pełnoletnie;)

Nie używaj języka starszego od siebie!

- Wiele kompilatorów wciąż domyślnie używa standardu C89
 - On ma 26 lat!
- C99 jest już dostępne prawie wszędzie!
 - ▶ GCC od... bardzo dawna
 - Clang od początku istnienia
 - ▶ Visual C++... hmm... cóż... :(
- C11 coraz szerzej dostępne
- Dużo wygodnych usprawnień
 - Deklaracje zmiennych w dowolnym miejscu
 - ► Lokalne tablice o "zmiennym" rozmiarze
 - Wygodniejsze definicje stałych tablicowych i strukturalnych
 - ...

C99 jest fajne! Lokalne tablice o "zmiennym" rozmiarze

- NIE chodzi o tablice dynamiczne
- Przykład:

```
void read_command(FILE *file) {
    size_t command_size;
    fread(&command_size, sizeof(command_size), 1, file);
    char command[command_size];
    // ...
}
```

- Dane są alokowane na stosie
 - wydajniejsze niż malloc()/free()
- Nie przesadzajmy z rozmiarem danych!
 - Jeśli wyjdziemy poza rozmiar stosu (kilka MB), błąd będzie bardzo trudny do wykrycia

C99 jest fajne! Lepsze tablice i struktury

Przypisania do konkretnych pól

```
struct tm my_time = {
    .tm_hour = 21,
    .tm_min = 37
};
```

Nienazwane lokalne struktury

C99 jest fajne! Typy danych (1/2)

- Jaki zakres ma int?
- **-**2^31 .. 2^31 1?
- ŽLE!
 - ► Tak naprawdę nie wiadomo (5)
- Na szczęście jest rozwiązanie!
 - #include <stddef.h>
 #include <stdint.h>
 - ▶ int8 t, int16 t, int32 t, int64 t
 - ▶ uint8_t, uint16_t, uint32_t, uint64_t
 - size_t typ wyniku zwracanego przez sizeof
 - ptrdiff t wynik odejmowania dwóch wskaźników
 - ▶ (u) intptr_t int o rozmiarze równym rozmiarowi wskaźnika

C99 jest fajne! Typy danych (2/2)

- Kiedy czego używać?
- ▶ Bierzmy pod uwagę to, skąd lub dokąd docierają dane
- Przykłady
 - Wartość przekazywana później do funkcji przyjmującej int int
 - Rozmiar tablicy lub indeks do niej size t
 - ► Wartości dla protokołów sieciowych (u) int{8,16,32,64} t
- printf, scanf
 - #include <inttypes.h>
 int16_t val;
 scanf("%" SCNd16, &val);
 printf("Hello, %" PRId16 "!\n", val);
- Uwaga na overflow!
 - Według standardu wynik przekroczenia zakresu typów ze znakiem jest NIEOKREŚLONY.
 - Na niektórych architekturach powoduje przerwanie programu.

C nie jest wyjątkowe!

- W C da się pisać:
 - obiektowo
 - komponentowo
 - funkcyjnie (sort of)
 - ...co nie znaczy że zawsze należy;)
- W C można (i należy!) używać wzorców projektowych

Jak ogarnąć moduły?

- W C nie ma namespace'ów
- ...dlatego tworzymy własne!
- Przykład na naszym githubie: https://github.com/AVSystem/avs_commons
- Funkcje "publiczne" mają nazwę zaczynającą się od nazwy modułu
 - avs_buffer_*, avs_list_*, avs_unit_*
- Funkcje wewnętrzne modułu (udostępnione pomiędzy jednostkami translacji)
 - avs_buffer_*, avs_list_*, avs_unit_*
 - ▶ Nie są zdefiniowane w publicznych nagłówkach



Programowanie prawie-funkcyjne w C

- Jedna z zalet wynikających z niskopoziomowości C
- Każda funkcja znajduje się pod jakimś, dobrze określonym adresem w pamięci
- Ten adres zawsze można pobrać i przekazać dalej...

Programowanie prawie-funkcyjne w C: Deklaracje

- Funkcja
 - ▶ int func(double arg);
- Typ funkcyjny
 - typedef int func_t(double);
 - Specyficzne własności nie można prawie nic z nim zrobić!
- Wskaźnik na funkcję
 - ▶ int (*func ptr)(double);
 - ▶ func t *func ptr;
- Typ wskaźnika na funkcję:
 - typedef int (*func ptr t) (double);
 - typedef func_t *func_ptr_t;

Programowanie prawie-funkcyjne w C: Wskaźniki na funkcje (1/2)

- int (*f) (const char *) = puts; // lub &puts
 f("Hello, world!"); // lub (*f) (...)
- Wydajność?
 - Niższa niż przy bezpośrednim wywołaniu funkcji potrzeba dereferencji wskaźnika
 - Czy mamy alternatywę?
 - enum reprezentujący listę możliwych funkcji
 - wybór w switchu lub drabince ifów
 - efekt podobna wydajność, a tracimy na elastyczności

Programowanie prawie-funkcyjne w C: Wskaźniki na funkcje (2/2)

- Wskaźnik na dowolne dane można zrzutować na void *
- Wskaźnika na funkcję nie można.
- Dlaczego?
 - Harvard architecture oddzielna pamięć na kod i dane
 - Stosowana w niektórych mikrokontrolerach
 - Adresy pamięci kodu i danych mogą mieć różny rozmiar!
 - Niektóre modele pamięci DOS dalekie (segment+offset) vs. bliskie (offset) wskaźniki
- ▶ Jeżeli **BARDZO** potrzebujemy generycznego wskaźnika na dowolny kod, możemy rzutować na wskaźnik do dowolnej umownie przyjętej sygnatury
 - ▶ Np. typedef int (*generic_fptr_t)(...);
 - Koniecznie trzeba pilnować, żeby zrzutować go do oryginalnego typu przed wywołaniem inaczej nie wiadomo co się stanie...

Programowanie prawie-funkcyjne w C: Praktyka (1/2)

- Rejestracja hooków użytkownika
 - typedef int after_connection_t(...);
 int register_after_connection_hook(after_connection_t *hook);
 register_after_connection_hook(my_after_connection);
- Funkcje wyższego rzędu

 - Zawsze dodawajmy wskaźnik na dane użytkownika do API!

Programowanie prawie-funkcyjne w C: Praktyka (2/2)

```
typedef struct {
    size t counter;
} count elements ctx t;
static int count elements clb(element t *element, void *ctx) {
    (void) element;
    ((count_elements_ctx_t *) ctx)->counter++;
    return 0;
size t count elements(container t *container) {
    count elements ctx t ctx = \{ 0 \};
    foreach element(container, count_elements_clb, &ctx);
    return ctx.counter;
```

Programowanie obiektowe w C (1/4)

```
typedef struct animal vtable animal vtable t;
typedef struct {
    const animal vtable t *vtable;
} animal abstract t;
struct animal vtable {
    void (*make sound) (animal abstract t *self);
    int (*eat) (animal abstract t *self, const char *meal);
};
void animal make sound(animal abstract t *self) {
    self->vtable->make sound(self);
int animal eat(animal abstract t *self, const char *meal) {
    return self->vtable->eat(self, meal);
```

Programowanie obiektowe w C (2/4)

```
typedef struct {
    const animal vtable t *vtable;
   unsigned stomach capacity;
} dog t;
static void dog make sound(animal abstract t *self)
    (void) self;
   printf("woof!\n");
static int dog eat(animal abstract t *self ,
                   const char *meal) {
   dog t *self = (dog t *) self ;
    if (self->stomach capacity >= strlen(meal)) {
        self->stomach capacity -= strlen(meal);
        return 0;
    } else {
        return ERR STOMACH FULL;
```

```
static const animal_vtable_t DOG_VTABLE = {
    .make_sound = dog_make_sound,
    .eat = dog_eat
};

animal_abstract_t *dog_new(void) {
    dog_t *dog = (dog_t *) malloc(sizeof(dog_t));
    if (!dog) {
        return NULL; // no memory
    }
    dog->vtable = &DOG_VTABLE;
    dog->stomach_capacity = 100;
    return (animal_abstract_t *) dog;
}
```

Programowanie obiektowe w C (3/4)

```
typedef struct {
    const animal vtable t *vtable;
   bool good_mood;
} cat t;
static int cat make sound(animal abstract t *self ) {
    cat t *self = (cat t *) self ;
    if (self->good_mood) {
        printf("meow!\n");
    } else {
        printf("purr >_<\n");</pre>
```

Programowanie obiektowe w C (4/4)

```
int main(int argc, char *argv[]) {
    assert(argc == 3);
    animal abstract t *my pet = NULL;
    if (strcmp(argv[1], "cat") == 0) {
        my pet = cat new();
    } else if (strcmp(argv[1], "dog") == 0) {
        my pet = dog new();
    if (!my pet) {
        printf("I can't have a %s\n", argv[1]);
        return -1;
    animal make sound (my pet);
    if (animal_eat(my_pet, argv[2])) {
        printf("My pet couldn't eat %s\n", argv[2]);
        return -1;
    return 0;
```

Dziękujemy!

Pytania?